

## Capítulo 5 : Ajuste de Funções.

### 5.1. Preliminares.

No capítulo 4 vimos como aproximamos uma função por um polinômio e por splines. O ajuste é outra técnica de aproximação de funções que tem características diferentes da interpolação.

Em geral se aplica a um conjunto de dados experimentais:  $\{(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)\}$ , e deseja-se obter a lei  $y = f(x)$  que relaciona  $x$  com  $y$  e a partir dela, calcular  $y$  para um certo  $x$  que não dos dados experimentais. O ajustamento traduz um comportamento médio (extrapolação com certa margem de segurança).

Para um conjunto de vários elementos a seleção da aproximação dos dados por interpolação pode ocupar muita memória e tempo de processamento. Embora não conheçamos a função que originou os dados, pela origem do problema podemos saber o tipo da função que estabelece a relação entre  $x$  e  $y$ .

#### *Critérios para a medida da qualidade de Ajuste.*

Para ajustar um conjunto de dados a uma função é preciso estabelecer o tipo de curva e calcular os parâmetros dessa curva. Se conhecermos os parâmetros dessa curva poderemos calcular  $f(x_i)$  e comparar com o valor dado  $y_i$ .

$$\therefore \tilde{R}_i = f^*(x_i) - y_i \quad (5.1.1)$$


Resíduo (erro).

A primeira idéia para avaliarmos a qualidade do ajuste seria:

*Critério 1:* Todos os erros devem tender a zero. Tal critério não é utilizável, ou então cairíamos no problema de interpolação, onde exigimos que:

$f(x_i) = y_i = f^*(x_i)$ , isto é,  $R_i = 0$  para  $i = 0, 1, \dots, m$ .

*Critério 2:* A soma do erro deve ser tão pequena quanto possível, isto é,  $\sum_i R_i$  deve ser minimizada. Tal critério não é utilizável, pois podemos ter uma soma de erros nula sem que o ajuste seja bom. A figura 5.1.1. ilustra tal fato:



*Critério 3:* A soma do erro em valor absoluto deve ser a menor possível, isto é,

$\sum_{j=1}^m |f^*(x_i) - y_i|$  deve ser mínima.

OBS :  $| \cdot |$  não é diferenciável, problema achar o mínimo.

*Critério 4 (difícil) :*  $\max_{1 \leq i \leq n} |f^*(x_i) - y_i|$  deve ser o mínimo.

*Critério 5:* Método dos mínimos quadrados.  $\sum_{i=1}^n R_i^2$  é minimizado.

Neste caso, nunca teremos uma soma nula (o que ocorreria só na interpolação) e a função “quadrado” é facilmente diferenciável. É o critério mais usado.

## 5.2. Método dos Mínimos Quadrados.

Outros Nomes: Análise de Regressão, Suavização Dados, Otimização Linear.

No caso do ajuste de dados, a técnica dos mínimos quadrados é utilizada no cálculo de um conjunto de constantes  $c_j$  de uma função  $f^*$  que aplicada a uma função  $f$ , desconhecida, da forma:

$$f^*(x) = c_1\phi_1(x) + \dots + c_n\phi_n(x) \quad (5.1-1)$$

observe que as constantes desconhecidas  $c_j$  aparecem linearmente, embora as funções básicas  $\phi_1, \dots, \phi_n$  possam ser funções não lineares em  $x$ .

A escolha de  $\phi_1, \dots, \phi_n$  é de acordo com a natureza do problema (dados experimentais e pode não ser fácil escolhê-las de modo a ter uma solução razoável). Então

$$R = \sum_{j=1}^m [y_i - f^*(x_i)]^2 \quad (5.1-2)$$

onde  $R$  seja mínima. De (4.1-1) e (5.1-2) vem:  $R = R(c_1, \dots, c_m)$  e portanto passarão por um mínimo quando as  $m$  derivadas parciais se anularem simultaneamente, ou seja, teremos:

$$\frac{\partial R}{\partial c_j} = 2 \sum_{i=1}^m [f^*(x_i) - y_i] \frac{\partial f^*(x_i)}{\partial c_j} \equiv 0 \quad (5.1-3)$$

para  $j = 1, \dots, n$  (são mínimos pois a função  $[f^*(x_i) - y_i]^2$  é uma grandeza sempre positiva), com

$$\frac{\partial f^*(x_i)}{\partial c_j} = \phi_j(x_i) \quad (5.1-4)$$

$j = 1, \dots, n$  ;  $i = 0, 1, \dots, m$  ;  $m \leq n$ .

Note (5.1-3) é um sistema de n equações algébricas lineares e n incógnitas  $c_1, \dots, c_m$  ; são denominadas de equações normais, portanto

$$\begin{cases} A_{11}C_1 + A_{12}C_2 + \dots + A_{1n}C_n = B_1 \\ A_{21}C_1 + A_{22}C_2 + \dots + A_{2n}C_n = B_2 \\ \vdots \\ A_{n1}C_1 + A_{n2}C_2 + \dots + A_{nn}C_n = B_n \end{cases} \quad (5.1-5)$$

$$\therefore A_{kj} = A_{jk} \quad (5.1-6)$$

$$A_{kj} = \sum_{k=1}^m \phi_j(x_k) \cdot \phi_i(x_k) \quad (5.1-7)$$

$$C = (C_1, C_2, \dots, C_n)^T ; \quad B = (B_1, B_2, \dots, B_n)^T$$

$$B_i = \sum_{k=1}^m f(x_k) \cdot \phi_i(x_k) \quad (5.1-8)$$

Demonstra-se que se as funções escolhidas,  $\phi_1(x), \phi_2(x), \dots, \phi_n(x)$ , forem linearmente independentes, o determinante da matriz A é diferente de zero e, portanto, o sistema linear admite solução única:  $\bar{c}_1, \bar{c}_2, \dots, \bar{c}_n$ . Ainda mais, demonstra-se também que esta solução  $\bar{c}_1, \bar{c}_2, \dots, \bar{c}_n$  é o ponto em que a função  $f(c_1, c_2, \dots, c_n)$  atinge seu valor mínimo.

**Exemplo 1:** Considere a tabela

x	-1.0	-1.75	-0.6	-0.5	-0.3	0.0	0.2	0.4	0.5	0.7	1
f(x)	2.05	-1.153	0.45	0.4	0.5	0.0	0.2	0.6	0.512	1.2	2.05

feito o diagrama de dispersão, deve ser ajustada por uma parábola passando pela origem, ou seja,  $f(x) \approx \phi(x) = \alpha x^2$  (neste caso temos apenas uma função  $\phi(x) = x^2$ ).

Temos pois de resolver apenas a equação

$$\begin{aligned} \left| \sum_{k=1}^{11} \phi(x_k) \cdot \phi(x_k) \right| \alpha &= \sum_{k=1}^{11} f(x_k) \cdot \phi(x_k) \\ \left| \sum_{k=1}^{11} \phi(x_k)^2 \right| \alpha &= \sum_{k=1}^{11} f(x_k) \cdot \phi(x_k) \\ \left| \sum_{k=1}^{11} (x_k^2)^2 \right| \alpha &= \sum_{k=1}^{11} x_k^2 \cdot f(x_k) \end{aligned}$$

Continuando a tabela com  $\phi(x_k) \cdot \phi(x_k)$  e  $\phi(x_k) \cdot f(x_k)$ , temos: