

Ajuste de Funções.

Em geral se aplica a um conjunto de dados experimentais: $\{(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)\}$, e deseja-se obter a lei $y = f(x)$ que relaciona x com y e a partir dela, calcular y para um certo x que não dos dados experimentais. O ajustamento traduz um comportamento médio (extrapolação com certa margem de segurança).

Para um conjunto de vários elementos a seleção da aproximação dos dados por interpolação pode ocupar muita memória e tempo de processamento.

Embora não conheçamos a função que originou os dados, pela origem do problema podemos saber o tipo da função que estabelece a relação entre x e y .

Critérios para a medida da qualidade de Ajuste. Método dos mínimos quadrados- Outros Nomes: Análise de Regressão, Suavização Dados, Otimização Linear.

No caso do ajuste de dados, a técnica dos mínimos quadrados é utilizada no cálculo de um conjunto de constantes c_j de

uma função f^* que aplicada a uma função f , desconhecida, da forma:

$$f^*(x) = c_1 f_1(x) + \dots + c_n f_n(x)$$

observe que as constantes desconhecidas c_j aparecem linearmente, embora as funções básicas f_1, \dots, f_n possam ser funções não lineares em x .

A escolha de f_1, \dots, f_n é de acordo com a natureza do problema (dados experimentais e pode não ser fácil escolhê-las de modo a ter uma solução razoável). Então

$$R = \sum_{j=1}^m [y_i - f^*(x_i)]^2$$

onde R seja mínima.

$R = R(c_1, \dots, c_m)$ e portanto passarão por um mínimo quando as m derivadas parciais se anularem simultaneamente, ou seja, teremos:

$$\frac{\partial R}{\partial c_j} = 2 \sum_{i=1}^m [f^*(x_i) - y_i] \frac{\partial f^*(x_i)}{\partial c_j} \equiv 0$$

para $j=1, \dots, n$ (são mínimos pois a função $[f^*(x_i) - y_i]^2$ é uma grandeza sempre positiva), com

$$\frac{\partial f^*(x_i)}{\partial c_j} = f_j(x_i)$$

$j = 1, \dots, n$; $i = 0, 1, \dots, m$; $m \leq n$.

Note que temos um sistema de n equações algébricas lineares e n incógnitas c_1, \dots, c_m ; são denominadas de equações normais, portanto

$$\begin{cases} A_{11}C_1 + A_{12}C_2 + \dots + A_{1n}C_n = B_1 \\ A_{21}C_1 + A_{22}C_2 + \dots + A_{2n}C_n = B_2 \\ \vdots \\ A_{n1}C_1 + A_{n2}C_2 + \dots + A_{nn}C_n = B_n \end{cases}$$

$$\therefore A_{kj} = A_{jk}$$

$$A_{kj} = \sum_{k=1}^m \mathbf{f}_j(x_k) \cdot \mathbf{f}_i(x_k)$$

$$\mathbf{C} = (C_1, C_2, \dots, C_n)^T ;$$

$$\mathbf{B} = (B_1, B_2, \dots, B_n)^T$$

$$B_i = \sum_{k=1}^m f(x_k) \cdot \mathbf{f}_i(x_k)$$

Demonstra-se que se as funções escolhidas, $\mathbf{f}_1(x), \mathbf{f}_2(x), \dots, \mathbf{f}_n(x)$, forem linearmente independentes, o determinante da matriz A é diferente de zero e, portanto, o sistema linear admite solução única: $\bar{C}_1, \bar{C}_2, \dots, \bar{C}_n$. Ainda mais, demonstra-se também que esta solução $\bar{C}_1, \bar{C}_2, \dots, \bar{C}_n$ é o ponto em que a função $f(C_1, C_2, \dots, C_n)$ atinge seu valor mínimo.

Exemplo 1: Considere a tabela

x	-1.0	-1.75	-0.6	-0.5	-0.3	0.0	0.2	0.4	0.5	0.7	1
$f(x)$	2.05	-1.153	0.45	0.4	0.5	0.0	0.2	0.6	0.512	1.2	2.05

feito o diagrama de dispersão, deve ser ajustada por uma parábola passando pela origem, ou seja, $f(x) \approx \phi(x) = \alpha x^2$ (neste caso temos apenas uma função $\phi(x) = x^2$).

Temos pois de resolver apenas a equação

$$\begin{aligned} \left| \sum_{k=1}^{11} f(x_k) \cdot f(x_k) \right| \alpha &= \sum_{k=1}^{11} f(x_k) \cdot f(x_k) \\ \left| \sum_{k=1}^{11} f(x_k)^2 \right| \alpha &= \sum_{k=1}^{11} f(x_k) \cdot f(x_k) \\ \left| \sum_{k=1}^{11} (x_k^2)^2 \right| \alpha &= \sum_{k=1}^{11} x_k^2 \cdot f(x_k) \end{aligned}$$

Usando a tabela com $g(x_k)g(x_k) \quad g(x_k)f(x_k)$: temos

$$a = \frac{5.8756}{2.8464} = 2.06442$$

Logo $f(x) \approx 2.0642 x^2$ sendo esta parábola a que melhor se aproxima no sentido dos mínimos quadrados a função tabelada.

Se tratar-se de caso não-linear $y = a_1 e^{-a_2 x}$ tem-se aplicando log dos dois lados que

$$Y = a + BX$$

$$\text{onde} \quad Y = \ln y \quad a = \ln a_1, \quad a_2 = a_2$$

daí o método pode ser aplicado na resolução do problema linearizado.